PMlib 講習会

理化学研究所 計算科学研究機構
可視化技術研究チーム
2015年1月16日

本日使用する資料の入手方法

- 各自のPCへWebブラウザからアクセス・ダウンロード

- 本日使用する資料
  - スライドおよびハンズオンプログラムは下記から
  - https://github.com/mikami3heart/PMlib-tutorials

- PMlibパッケージ
  - パッケージファイル一式の tar.gz ファイル
  - http://avr-aics-riken.github.io/PMlib/

講習会の内容

- PMlib概要
  - PMlibとは
  - PMlibの利用方法
  - PMlibの機能説明
- PMlibのインストールとテスト
  - PMlibの入手方法
  - テストシステムへのログイン
  - PMlibのインストール
  - 動作確認プログラムの実行
- ハンズオン
  - ハンズオンプログラムについて
  - プログラムの実行
  - プログラムへのPMlibのくみこみ
  - プログラムのPMlib統計情報の解釈と検討

PMlibとは

- アプリケーション計算性能モニター用のクラスライブラリ
- ユーザーライブラリとしてもシステムライブラリとしても利用可
- オープンソースソフトウエア（理研 AICSが開発・提供）
- アプリケーション中に計測区間を指定し、実行終了時に区間の統計情報を出力する
- ソースプログラム中でPMlibライブラリを呼び出して利用する
- アプリケーション性能改善用の一時的な利用だけでなく、プロダクションランに常用して性能モデリングの支援に用いられる事を期待
- APIはC++に対応

性能統計ツールの位置づけ

- オープンソース性能統計ツール一般
  - Gprof: 簡易機能、コンパイラに制約
  - Scalasca: 高機能、Score-P共通インフラ
  - TAU: 高機能
  - PAPI : HWPCへのアクセス
  - など多数、、、プラス
  - PMlib

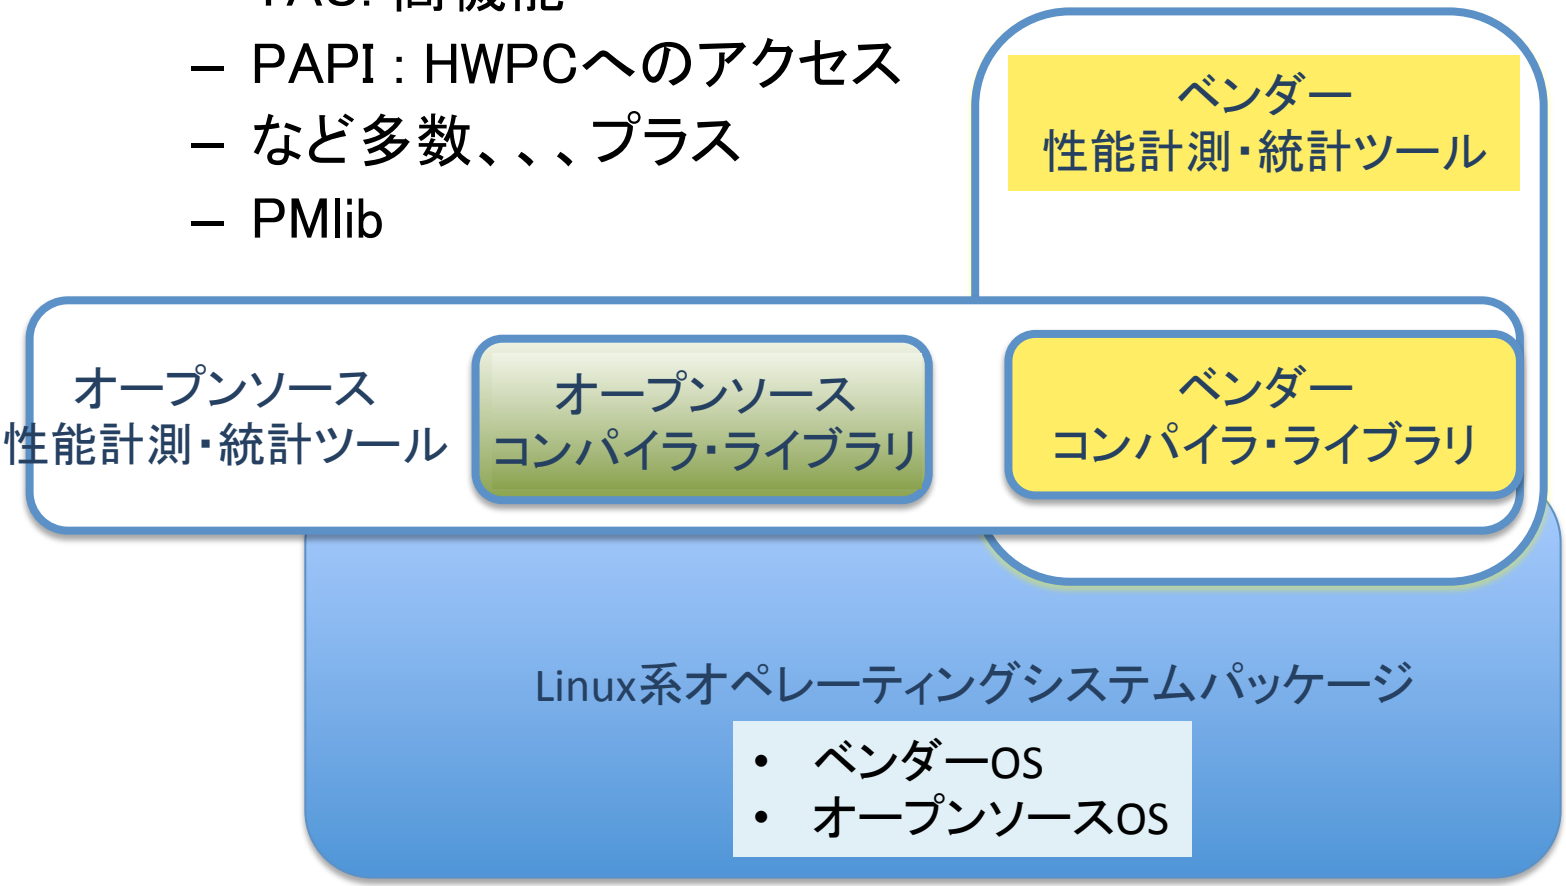

ベンダーツール

X86系
- Intel
- PGI
- Cray

Sparc系
- 富士通
- Oracle

Power系
- 日立
- IBM

その他の系
- GPU
- Phi
- SX

各ツールの位置づけ

- ベンダー性能計測・統計ツール
  - 〇豊富な機能、高度なインタフェイス、システムに統合化された安心感、詳しいドキュメント、ベンダーによるサポート
  - △習熟に相当期間が必要、システム機種毎にツールが決まってしまう、それなりの価格
- オープンソース性能統計ツール
  - 〇各ツール毎に高機能、無料
  - △ユーザーインタフェイスが個性的、インストールの手間・利用方法の習熟がそれなりに大変→周囲にツールをよく知っている人がいないとハードルは高い
- 高機能GUIツールのハードル

- PMlib
  - 機能・出力情報をテキストに絞ったコンパクトなツール

高機能GUIベースツールのハードル

- 見た目の豪華さ ∝ 利用に必要な習熟期間の長さ

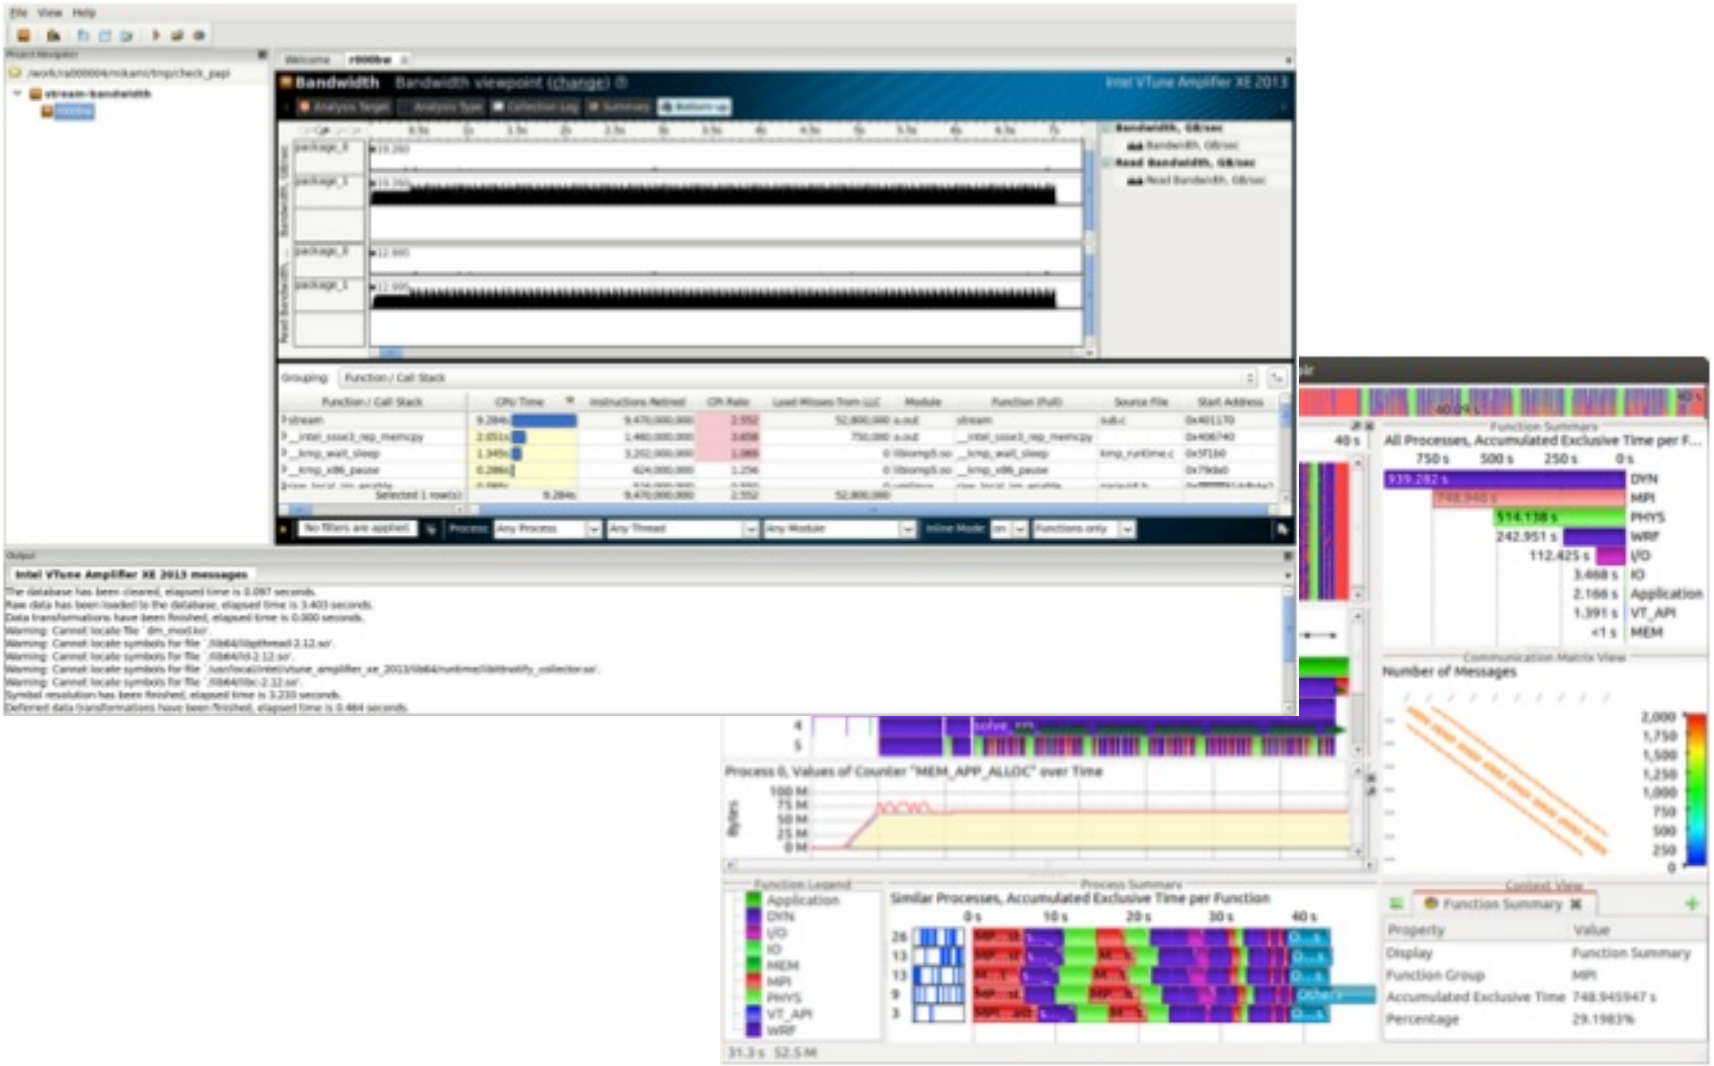

PMlibの特徴

- PMlibの特徴
  - 機能を絞ったテキストベースのコンパクトなツール
  - インストール・利用が容易
    - プラットフォーム依存性が低い
  - 利用のオーバーヘッドが少ない軽量ツール
  - 性能情報の採取方法を選択可能
    - ユーザ自身の明示的申告か、HWPCによる自動取得
  - 性能計測結果は指定区間毎に出力
    - 出力タイプ1:全プロセスの平均した基本情報
    - 出力タイプ2:MPIランク(プロセス)毎の情報
    - 出力タイプ3:ハードウエアイベントグループの情報

PMlibが対応する並列プログラムモデル

- シリアルプログラム
- OpenMP（SMPスレッド）並列プログラム
  - 測定区間内にOpenMPループを含む場合に相当
  - ただしスレッド自身からのPMlibよびだしには未対応
- MPI並列プログラム
- MPIとOpenMPの組み合わせ並列プログラム
- APIはC++に対応

PMlibの利用方法

- PMlibライブラリのインストール
- アプリケーション へPMlib呼び出しを追加
- アプリケーションの実行
- PMlib出力情報の評価

PMlib利用プログラム例

- 元のソース

```
int main (int argc, char *argv[])
{
    subkerel(); //演算を行う関数

    return 0;
}
```

PMlib組み込み後のソース

```
#include <PerfMonitor.h>
using namespace pm_lib;
PerfMonitor PM;
int main (int argc, char *argv[])
{
    PM.initialize();
    PM.setParallelMode("Serial", 1, 1);
    PM.setProperties("my_check_1", 1);
    PM.start("my_check_1");
    subkerel();
    PM.stop ("my_check_1", 0.0, 1);
    PM.gather();
    PM.print(stdout, "London", "Mr.Bean");
    PM.printDetail(stdout);
    return 0;
}
```

ヘッダー部

初期設定

測定区間

結果を出力

PMlib関数の仕様詳細

- 以降のスライドは「本日使用する資料のページ」からダウンロードしたファイルに含まれる
- 下のコマンドで復元したindex.htmlファイルを各自のPC上のWebブラウザで表示すると見やすい

```
$ tar –zxf PMlib-doxygen.tar.gz
$ cd PMlib-doxygen-html
$ file index.html
```

PMlib関数一覧

関数名	機能	呼び出し位置・回数	引数の仕様
initialize()	PMlib全体の初期化	冒頭・一回	(1)測定区間数
setParallelMode()	並列処理のタイプ指定	冒頭・一回	(1)並列モード、(2)スレッド数、(3)プロセス数
setRankInfo()	MPIランク番号の設定	冒頭・一回	(1)ランク番号
setProperties()	測定区間のラベル化	任意・一回	(1)ラベル、(2)測定対象タイプ、(3)排他指定
start()	測定の開始	任意・任意 （startとstopでペア）	(1)ラベル
stop()	測定の停止	任意・任意 （startとstopでペア）	(1)ラベル、(2)計算量、(3)計算のタスク数
gather()	測定結果情報をマスタープロセスに集約	測定終了後・一回	なし
print()	測定区間毎の基本統計結果表示	測定終了後・一回	(1)出力ファイルポインタ、(2)ホスト名、(3)実施者名
printDetail()	並列ランク・性能情報毎の詳細表示	測定終了後・一回	(1)出力ファイルポインタ

これら関数の仕様や引数詳細説明は Doxygenで生成・表示

各関数の仕様（Webブラウザで表示）

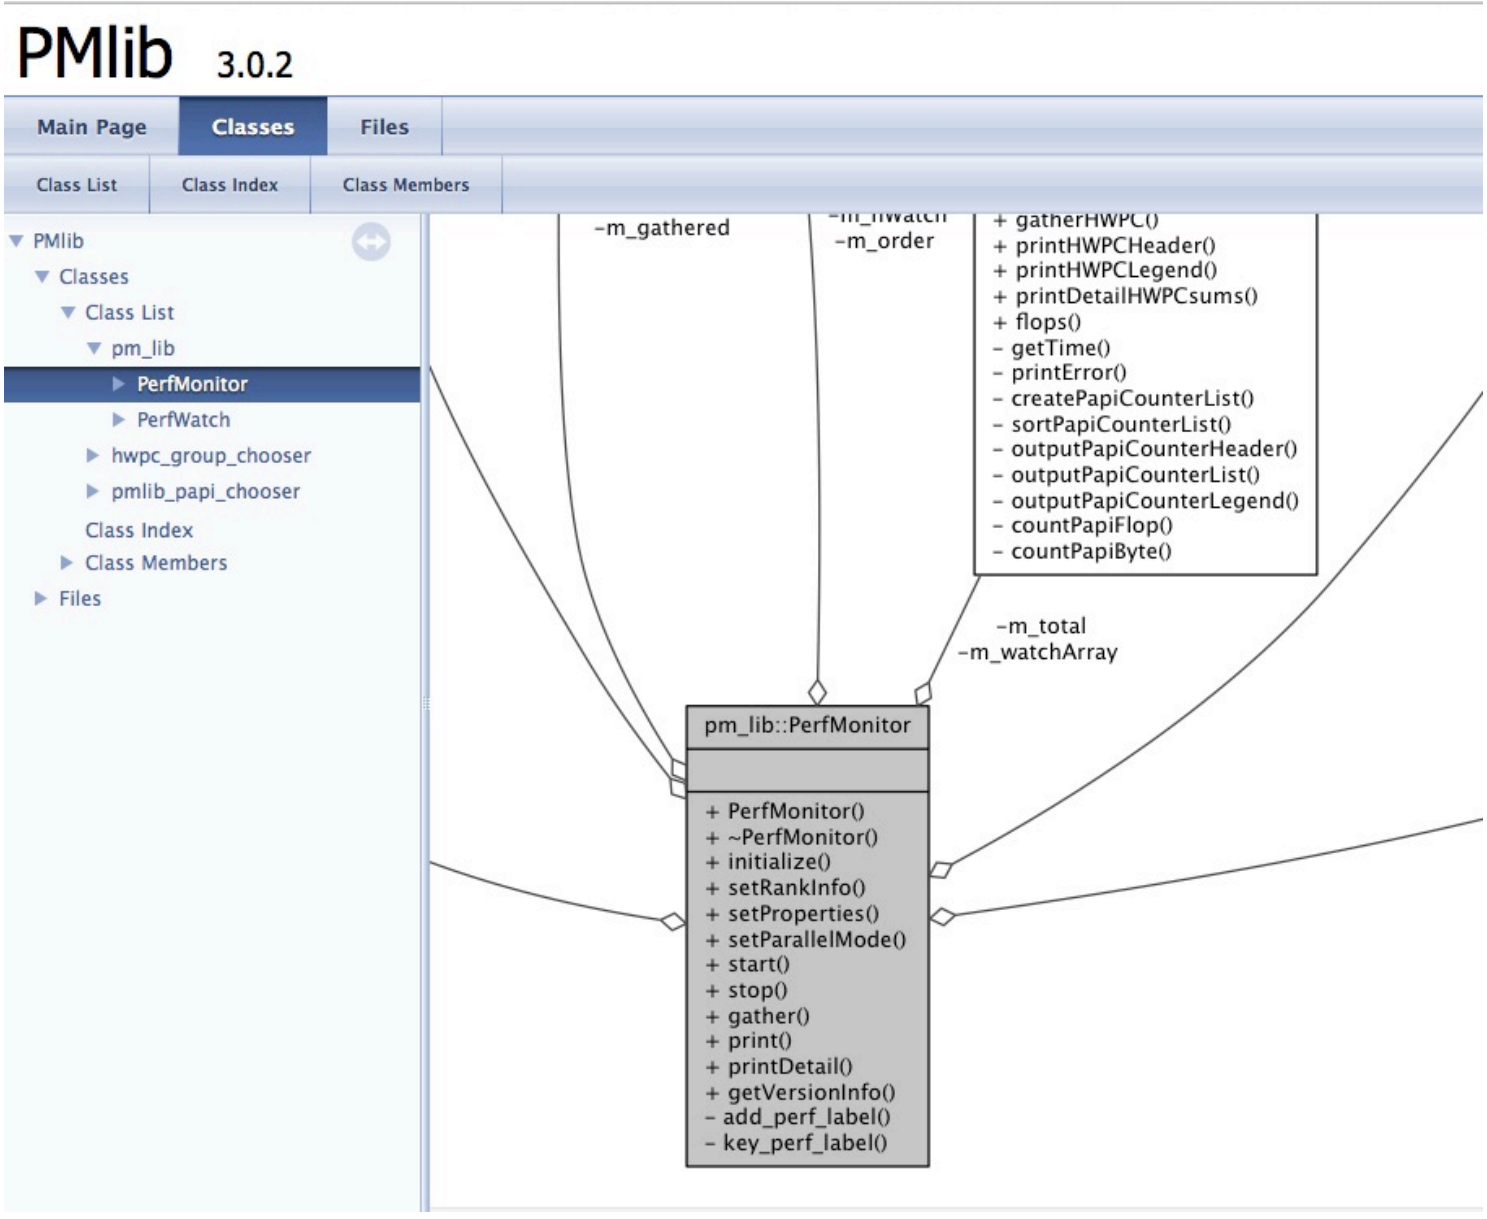

各関数の仕様　initialize()

void pm_lib::PerfMonitor::initialize (int init_nWatch = 100) inline

初期化.

測定区間数分の測定時計を準備. 全計算時間用測定時計をスタート.

Parameters

[in] **（引数はオプション）** init_nWatch 最初に確保する測定区間数

Note

測定区間数 m_nWatch は動的に増えていく事もある 最初にinit_nWatch区間分を確保し、不足したらさらにinit_nWatch追加する

Here is the call graph for this function:

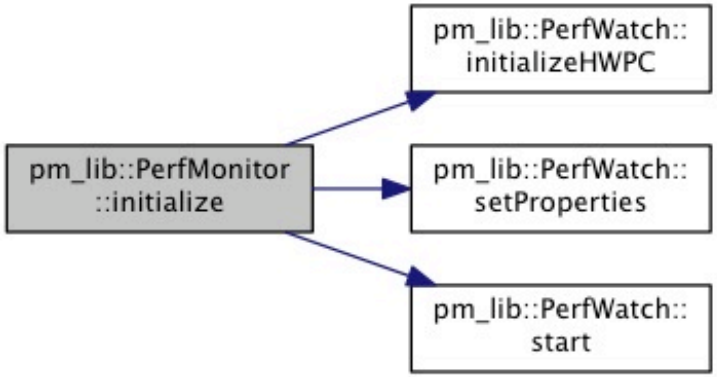

各関数の仕様　setParallelMode()

```
void pm_lib::PerfMonitor::setParallelMode ( const std::string &  p_mode,
                                            const int             n_thread,
                                            const int             n_proc
                                          )                                  inline
```

並列モードを設定

Parameters

- [in] **p_mode**　並列モード "Serial","OpenMP","FlatMPI","Hybrid"
- [in] **n_thread** スレッド数
- [in] **n_proc**　MPIプロセス数

各関数の仕様　setProperties()

```
void pm_lib::PerfMonitor::setProperties ( const std::string &  label,
                                          Type                  type,
                                          bool                  exclusive = true
                                        )
```

測定時計にプロパティを設定.

Parameters

[in]	**label**	ラベル文字列
[in]	**type**	測定対象タイプ(COMM:通信, CALC:計算, AUTO:自動決定)
[in]	**exclusive**	排他測定フラグ(ディフォルトtrue)

Note

測定区間を識別するためにlabelを用いる。 各labelに対応したキー番号 key は各ラベル毎に内部で自動生成する 最初に確保した区間数init_nWatchが不足したらさらにinit_nWatch区間追加する

Here is the call graph for this function:

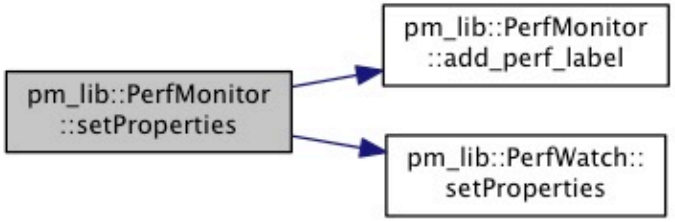

各関数の仕様　start()/stop()

void pm_lib::PerfMonitor::start (const std::string & label) inline

測定スタート.

Parameters

[in] **label** ラベル rev.2.2 からkey キー番号ではなくラベルを使用

Here is the call graph for this function:

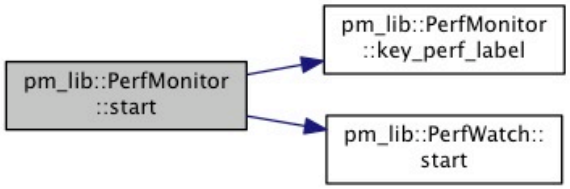

void pm_lib::PerfMonitor::stop (const std::string & label,
double flopPerTask = 0.0,
unsigned iterationCount = 1
) inline

測定ストップ.

Parameters

[in] **label** ラベル rev.2.2 からkey キー番号ではなくラベルを使用

[in] **flopPerTask** 「タスク」あたりの計算量/通信量(バイト) (ディフォルト0)

[in] **iterationCount** 実行「タスク」数 (ディフォルト1)

Here is the call graph for this function:

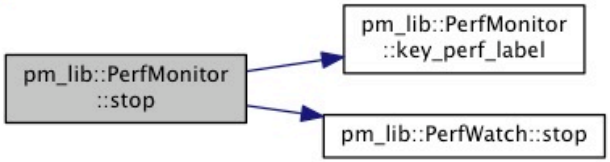

各関数の仕様　gather()

void pm_lib::PerfMonitor::gather (void　)

全プロセスの全測定結果情報をマスタープロセス(0)に集約.

全計算時間用測定時計をストップ.

各関数の仕様　print()/printDetail()

```
void pm_lib::PerfMonitor::print ( FILE *              fp,
                                  const std::string  hostname,
                                  const std::string  operatorname
                                )
```

測定結果の基本統計情報を出力.

排他測定区間のみ

Parameters

[in]	fp	出力ファイルポインタ
[in]	hostname	ホスト名
[in]	operatorname	作業者名

Note

ノード0以外は, 呼び出されてもなにもしない

```
void pm_lib::PerfMonitor::printDetail ( FILE *  fp )
```

詳細な測定結果を出力.

ノード毎に非排他測定区間も出力

Parameters

[in] fp 出力ファイルポインタ

Note

ノード0以外は, 呼び出されてもなにもしない

各関数の仕様　setRankInfo()

void pm_lib::PerfMonitor::setRankInfo (const int myID)

ランク番号の通知

Parameters

[in] **myID** 通常はMPIランクIDを指定する

Pmlibの動作確認がとれているシステム

- 京/FX10
  - ログインノードでのクロスコンパイル環境
  - 計算ノードでのネイティブコンパイル環境
  - 富士通コンパイラ＋MPI
- Intel Xeon E5 クラスタ
  - Intelコンパイラ＋IntelMPI
  - GNUコンパイラ+OpenMPI/gnu
  - PGIコンパイラ+OpenMPI/pgi
- 必要なソフトウエア環境
  - C, C++ compiler
  - HWPC/PAPIを組み込む場合はLinux kernel 2.6.32+

PMlibの入手方法

- PMlibパッケージの入手方法
  - 下記公開リポジトリからDownload
  - http://avr-aics-riken.github.io/PMlib/

- PMlibに関するドキュメント
  - パッケージに含まれるdoc/ディレクトリ以下にある
    - How_to_use_PMlib.pdf　:クラスライブラリの説明書
    - PMlib_getting_started.pdf :本資料

PMlib計算性能モニター機能

- 指定した測定区間毎に性能統計情報を蓄積・出力
- 各測定区間は小数のプロパティを持つ
  - ラベル：任意の文字列（統計情報出力時のラベル ）
  - 測定対象タイプ：「計算時間」、「通信時間」、「自動決定」
  - 排他測定フラグ：「排他測定」または「非排他測定」
- 性能統計の種類と算出方法を選択
  - 計算量をユーザが明示的に申告する場合
    - 測定区間の「量」を計算式で引数として与える
    - 測定対象タイプにより、「量」を浮動小数点演算量あるいはデータ移動量として評価

性能統計：明示的な自己申告

- 計算量をユーザが明示的に申告する場合
  - ソースプログラムに記述されたの計算式に忠実な実行性能を測定可能
  - 演算の種類に応じて四則演算の「重さ」を指定することも可能
    - 計算式を実行するのに必要な演算数は、計算の種類、実行するシステム毎で異なる
    - 例えばFX10のPA情報から評価すると．．．
      - +, −, x　：　1 flop
      - ÷　：　8 flops（単精度），13 flops（倍精度）
      - abs()　：　1 flops
    - 加算・乗算以外の複雑な演算も一回の計算として計上可能
  - 実行時の各セクションのタイミングと演算数を積算して記録
    - タイミング測定区間はラベル管理で，コーディング時に指定

性能統計：計算量の自動算出

- 実行するシステムのCPUハードウエア性能カウンター(HWPC)を内部に持ち、そのイベント情報を測定可能な場合に採取して出力
- HWPCのイベントリスト別表
- PMlib用にイベントの種類毎グループを定義
  - FLOPS
  - VECTOR
  - BANDWIDTH
  - CACHE
  - CYCLE
- プログラム実行時に環境変数で動的に選択する
  - マスタープロセス(MPI rank 0)の測定値を代表値として出力
  - もしOpenMPスレッド並列処理の場合はマスタープロセスが発生するスレッド群の合計値を出力

出力する情報

- １、基本プロファイル
  - 全プロセスの平均情報
  - プログラム終了時に各MPIプロセス（ランク）の情報をマスターランクに集計。統計処理して出力
- ２、詳細プロファイル(1：MPIプロセス毎)
  - MPIの各プロセス毎の情報を出力
- ３、詳細プロファイル(2：HWPCイベント統計)
  - 計測するHWPCイベントグループを環境変数で指定
  - プロセスがOpenMPスレッドを発生した場合各プロセスのにスレッド測定値を内部で合計する。マスタープロセス(MPI rank 0)の値を出力

基本プロファイル例

```
-----------------------------------------------------
     Report of Timing Statistics PMlib version 2.1.2
     Operator  : Kenji_Ono
     Host name : vsp22
     Date      : 2014/05/26 : 03:49:43

     Parallel Mode                     :   Hybrid (4 processes x 8 threads)

     Total execution time            = 4.429648e+00 [sec]
     Total time of measured sections = 3.695136e+00 [sec]

     Statistics per MPI process [Node Average]
     Label                  |     call     |              accumulated time                  |          flop | messages[Bytes]
                            |              |   avr[sec]    avr[%]     sdv[sec]  avr/call[sec] |   avr         sdv         speed
     -----------------------+--------------+-----------------------------------------------+-----------------------------------
     Poisson_SOR2_SMA       :        26200   1.071254e+00   28.99   6.4536e-03   4.088757e-05    2.318e+10   0.000e+00    21.64 Gflops
     File_Output            :           11   8.003855e-01   21.66   1.3644e-02   7.276232e-02    1.311e+07   0.000e+00    16.38 Mflops
     Poisson_Src_Norm       :        13300   7.372693e-01   19.95   2.6937e-03   5.543378e-05    4.112e+10   0.000e+00    55.77 Gflops
     Sync_Pressure          :        26200   5.582871e-01   15.11   7.6391e-03   2.130867e-05    1.717e+09   0.000e+00     2.86 GB/sec
     A_R_Poisson_Src        :        13300   2.086478e-01    5.65   2.1901e-02   1.568781e-05    8.512e+05   0.000e+00     3.89 MB/sec
     Pseudo_Velocity        :          100   7.437694e-02    2.01   4.6558e-04   7.437694e-04    5.230e+09   0.000e+00    70.31 Gflops
     Projection_Velocity    :          262   7.227474e-02    1.96   6.3243e-04   2.758578e-04    1.820e+09   0.000e+00    25.18 Gflops
     Poisson_BC             :        26200   5.180532e-02    1.40   8.1025e-04   1.977302e-06    0.000e+00   0.000e+00     0.00 Mflops
     Poisson_Setup_for_Itr  :        13100   2.677810e-02    0.72   2.0531e-04   2.044130e-06    0.000e+00   0.000e+00     0.00 Mflops
     Sync_Velocity          :          100   1.325995e-02    0.36   3.9118e-04   1.325995e-04    1.573e+08   0.000e+00    11.05 GB/sec
     Sync_Pseudo_Velocity   :          100   1.039678e-02    0.28   7.3619e-04   1.039678e-04    3.932e+07   0.000e+00     3.52 GB/sec
     Variation_Space        :          100   9.503841e-03    0.26   5.3508e-05   9.503841e-05    4.260e+08   0.000e+00    44.82 Gflops
     Force_Calculation      :          100   6.575465e-03    0.18   7.8837e-03   6.575465e-05    0.000e+00   0.000e+00     0.00 Mflops
     Copy_Array             :          200   6.332040e-03    0.17   8.1976e-05   3.166020e-05    0.000e+00   0.000e+00     0.00 Mflops
     Projection_Velocity_BC :          262   6.013393e-03    0.16   8.4818e-05   2.295188e-05    0.000e+00   0.000e+00     0.00 Mflops
     Divergence_of_Pvec     :          100   5.138874e-03    0.14   5.1616e-05   5.138874e-05    2.425e+08   0.000e+00    47.19 Gflops
     A_R_Poisson_Norm       :          262   5.013704e-03    0.14   6.8061e-04   1.913628e-05    1.677e+04   0.000e+00     3.19 MB/sec
     Allocate_Arrays        :            4   5.009890e-03    0.14   2.1477e-04   1.252472e-03    0.000e+00   0.000e+00     0.00 Mflops
    ...
-----------------------+--------------+-----------------------------------------------+-----------------------------------
     Total                  |                3.695136e+00                                    7.225e+10                19.55 Gflops
     Performance            |                                                                                         78.21 Gflops
```

詳細プロファイル(1)

```
  Elapsed time variation over MPI ranks

*Initialization_Section
MPI_rank        call       accm[s] accm[%]    waiting[s]  accm/call[s]    flop|msg     speed
#0    :            1  1.623359e-01    4.39  6.041527e-04  1.623359e-01   0.000e+00     0.00 Mflops
#1    :            1  1.629400e-01    4.41  0.000000e+00  1.629400e-01   0.000e+00     0.00 Mflops
#2    :            1  1.543641e-01    4.18  8.575916e-03  1.543641e-01   0.000e+00     0.00 Mflops
#3    :            1  1.500421e-01    4.06  1.289797e-02  1.500421e-01   0.000e+00     0.00 Mflops

Allocate_Arrays
MPI_rank        call       accm[s] accm[%]    waiting[s]  accm/call[s]    flop|msg     speed
#0    :            4  5.146027e-03    0.14  9.012222e-05  1.286507e-03   0.000e+00     0.00 Mflops
#1    :            4  5.236149e-03    0.14  0.000000e+00  1.309037e-03   0.000e+00     0.00 Mflops
#2    :            4  4.867315e-03    0.13  3.688335e-04  1.216829e-03   0.000e+00     0.00 Mflops
#3    :            4  4.790068e-03    0.13  4.460812e-04  1.197517e-03   0.000e+00     0.00 Mflops

*Voxel_Prep_Section
MPI_rank        call       accm[s] accm[%]    waiting[s]  accm/call[s]    flop|msg     speed
#0    :            1  6.849098e-02    1.85  0.000000e+00  6.849098e-02   0.000e+00     0.00 Mflops
#1    :            1  6.354094e-02    1.72  4.950047e-03  6.354094e-02   0.000e+00     0.00 Mflops
#2    :            1  6.057596e-02    1.64  7.915020e-03  6.057596e-02   0.000e+00     0.00 Mflops
#3    :            1  2.413917e-02    0.65  4.435182e-02  2.413917e-02   0.000e+00     0.00 Mflops

Restart_Process
MPI_rank        call       accm[s] accm[%]    waiting[s]  accm/call[s]    flop|msg     speed
#0    :            1  4.053116e-06    0.00  9.536743e-07  4.053116e-06   0.000e+00     0.00 Mflops
#1    :            1  5.006790e-06    0.00  0.000000e+00  5.006790e-06   0.000e+00     0.00 Mflops
#2    :            1  3.099442e-06    0.00  1.907349e-06  3.099442e-06   0.000e+00     0.00 Mflops
#3    :            1  4.053116e-06    0.00  9.536743e-07  4.053116e-06   0.000e+00     0.00 Mflops
```

詳細プロファイル(2)

```
PMlib detected the CPU architecture:
   The available Hardware Performance Counter (HWPC) events depend on this CPU architecture.
       GenuineIntel
       Intel(R) Xeon(R) CPU E5-2670 0 @ 2.60GHz
   HWPC event values of the master rank, sum of threads. count unit in Giga (x 10e9)
   -                       :       LD_INS      SR_INS    :HIT_LFB     :L1_HIT     :L2_HIT     :L3_HIT     OFFCORE  [Mem GB/s]
   Initialization_Section  :        0.702       0.104       0.000       0.702       0.000       0.000       0.000       0.069
   Allocate_Arrays         :        0.125       0.023       0.000       0.125       0.000       0.000       0.000       2.371
   Voxel_Prep_Section      :        0.126       0.021       0.000       0.126       0.000       0.000       0.000       0.023
   Restart_Process         :        0.000       0.000       0.000       0.000       0.000       0.000       0.000      14.726
   Time_Step_Loop_Section  :        0.005       0.001       0.000       0.005       0.000       0.000       0.000       0.001
   Search_Vmax             :        0.027       0.003       0.001       0.026       0.000       0.000       0.002      64.719
   A_R_Vmax                :        0.024       0.005       0.000       0.024       0.000       0.000       0.000       3.541
   Copy_Array              :        0.074       0.042       0.022       0.051       0.000       0.000       0.004      36.320
   assign_Const_to_Array   :        0.010       0.005       0.000       0.009       0.000       0.000       0.000       2.816
   Flow_Section            :        0.005       0.001       0.000       0.005       0.000       0.000       0.000       0.001
   NS__F_Step_Section      :        0.004       0.001       0.000       0.004       0.000       0.000       0.000       0.035
   NS__F_Step_Sct_1        :        0.005       0.001       0.000       0.005       0.000       0.000       0.000       0.571
   NS__F_Step_Sct_2        :        0.005       0.001       0.000       0.005       0.000       0.000       0.000       0.047
   Pseudo_Velocity         :        0.721       0.363       0.002       0.705       0.000       0.000       0.010       8.086
```

PMlibのインストールとテスト

- PMlibの入手方法
- テストシステムへのログイン
- PMlibのインストール
- 動作確認プログラムの実行

PMlibのインストール　京コンピュータ(1)

- PMlibのインストール作業はログインノードでも計算ノードでも可能。本日はログインノードでインストール実施
- PMlibの利用は計算ノードアプリケーションが行う
- 任意のディレクトリでパッケージを展開。インストール先のディレクトリを　--prefix で指定しconfigureの実施。自動作成されるMakefileを用いて、makeの実施。

```
$ tar -zxf PMlib-master.2.1.3.vsh.tar.gz
$ ls -l
$ drwxr-xr-x 8 a03155 ra000004     4096  5月 26 04:30 PMlib-master
$ cd PMlib-master
$ ./configure CXX=mpiFCCpx CC=mpifccpx FC=mpifrtpx \
    CFLAGS='-Kopenmp,fast  -Ntl_notrt' \
    CXXFLAGS='-Kopenmp,fast -DUSE_PAPI  -Ntl_notrt' \
    --host=sparc64-unknown-linux-gnu   \
    --with-papi=yes  --with-example=yes \
    --prefix=${HOME}/pmlib/install_dir
$ make
$ make install
```

PMlibのインストール　京コンピュータ(2)

- 京でのインストール時間は数分で終了。正常にインストールされると以下のファイルができている。

```
$ ls -CF install_dir
bin/  doc/  include/  lib/  share/

$ ls -go install_dir/bin install_dir/include install_dir/lib

install_dir/bin:
total 4
-rwxr-xr-x 1 1563 May 26 19:18 pm-config

install_dir/include:
total 28
-rw-r--r-- 1 5798 May 26 19:18 PerfMonitor.h
-rw-r--r-- 1 6099 May 26 19:18 PerfWatch.h
-rw-r--r-- 1 1490 May 26 19:18 mpi_stubs.h
-rw-r--r-- 1  627 May 26 19:18 pmVersion.h
-rw-r--r-- 1 2079 May 26 19:18 pmlib_papi.h

install_dir/lib:
total 4136
-rw-r--r-- 1 4219910 May 26 19:18 libPM.a
-rw-r--r-- 1   11938 May 26 19:18 libpapi_ext.a
```

```
$ ls -go ./example/
total 2764
-rw-r--r-- 1   24025 May 26 19:17 Makefile
-rw-r--r-- 1    1649 May 23 00:14 Makefile.am
-rw-r--r-- 1   25696 May 23 00:14 Makefile.in
-rw-r--r-- 1    1130 May 23 00:14 Makefile_hand.fx10.login
-rw-r--r-- 1    1083 May 23 00:14 Makefile_hand.intel
-rwxr-xr-x 1 1062806 May 26 22:33 check_new_api
-rw-r--r-- 1    6096 May 23 00:14 check_new_api.c
-rwxr-xr-x 1 4409884 May 26 22:33 pmlib_test
-rw-r--r-- 1    2181 May 23 00:14 pmlib_test.cpp
-rw-r--r-- 1    1156 May 23 00:14 sub_kernel.c
```

PMlibを用いる　京コンピュータ(1)

- Example/ 以下のサンプルプログラムでPMlibを利用してみる

```
#!/bin/bash
set -x
date; hostname; /opt/FJSVXosPA/bin/xospastop
PMLIB=${HOME}/pmlib/PMlib-master
PMLIB_INCLUDE=-I${PMLIB}/include
PMLIB_LIB=${PMLIB}/src/libPM.a
PAPI_ROOT=/usr
PAPI_LIB="$PAPI_ROOT/lib64/libpapi.a $PAPI_ROOT/lib64/libpfm.a"
PAPI_EXT="$PMLIB/src_papi_ext/libpapi_ext.a”
CXXFLAGS="-Kfast,parallel,openmp ${PMLIB_INCLUDE} ${PAPI_INCLUDE}”
CCFLAGS="-std=c99 -Xg -Kfast,parallel,openmp ${PMLIB_INCLUDE} ${PAPI_INCLUDE}”
LDFLAGS="${PMLIB_LIB} ${PAPI_LIB} ${PAPI_EXT}”
SRC_DIR=${HOME}/pmlib/PMlib-master/example
WKDIR=/data/ra000004/a03155/tmp/check_pmlib ; mkdir -p $WKDIR
cd $WKDIR; if [ $? != 0 ] ; then echo '@@@ Directory error @@@'; exit; fi
cp $SRC_DIR/pmlib_main.cpp main.cpp
cp $SRC_DIR/sub_kernel.c sub.c
mpiFCC -c ${CXXFLAGS}  main.cpp
mpifcc -c ${CCFLAGS}  sub.c
mpiFCC    ${CXXFLAGS}  main.o sub.o ${LDFLAGS}
export OMP_NUM_THREADS=4
mpirun -np 2 ./a.out
```

Pmlibを用いる　京実行結果例 (1)

- 基本プロファイル＋MPIプロセス毎プロファイル

```
Report of Timing Statistics PMlib version 2.1.3
Operator  : RRR
Host name : QQQ
Date      : 2014/05/26 : 23:25:43
Parallel Mode                 :   Hybrid (2 processes x 4 threads)
Total execution time          = 7.231672e-01 [sec]
Total time of measured sections = 7.296531e-01 [sec]

Statistics per MPI process [Node Average]
Label    |     call     |            accumulated time                 |         flop | messages[Bytes]
         |              |   avr[sec]    avr[%]     sdv[sec]  avr/call[sec] |   avr         sdv         speed
---------+--------------+-------------------------------------------------+-----------------------------------
section1 :            2   4.918501e-01   67.41   2.4496e-02  2.459251e-01    0.000e+00   0.000e+00     0.00 Mflops
section2 :            1   2.378030e-01   32.59   1.9418e-03  2.378030e-01    4.000e+09   0.000e+00    16.82 Gflops
---------+--------------+-------------------------------------------------+-----------------------------------
Total    |              7.296531e-01                                  4.000e+09               5.48 Gflops
Performance|                                                                                  10.96 Gflops

-----------------------------------------------------
Elapsed time variation over MPI ranks

section1
MPI_rank       call       accm[s] accm[%]    waiting[s]  accm/call[s]    flop|msg     speed
#0    :          2  4.745290e-01   65.03  3.464222e-02  2.372645e-01   0.000e+00     0.00 Mflops
#1    :          2  5.091712e-01   69.78  0.000000e+00  2.545856e-01   0.000e+00     0.00 Mflops
section2
MPI_rank       call       accm[s] accm[%]    waiting[s]  accm/call[s]    flop|msg     speed
#0    :          1  2.391760e-01   32.78  0.000000e+00  2.391760e-01   4.000e+09    16.72 Gflops
#1    :          1  2.364299e-01   32.40  2.746105e-03  2.364299e-01   4.000e+09    16.92 Gflops
```

Pmlibを用いる　京実行結果例 (2)

- 環境変数を追加　export HWPC_CHOOSER=FLOPS

```
Statistics per MPI process [Node Average]
Label    |     call     |            accumulated time                |         flop | messages[Bytes]
         |              |  avr[sec]    avr[%]     sdv[sec]  avr/call[sec] |   avr         sdv         speed
---------+--------------+-------------------------------------------------+-------------------------------
section1 :            2   4.843562e-01   67.16   9.8485e-03  2.421781e-01    8.123e+09   2.828e+00    16.77 Gflops
section2 :            1   2.368304e-01   32.84   2.1871e-03  2.368304e-01    4.033e+09   7.071e-01    17.03 Gflops
---------+--------------+-------------------------------------------------+-------------------------------
Total    |              7.211865e-01                                1.216e+10              16.86 Gflops
Performance|                                                                                33.71 Gflops

-------------------------------------------------
PMlib detected the CPU architecture:
The available Hardware Performance Counter (HWPC) events depend on this CPU architecture.
          Sun
          Fujitsu SPARC64 VIIIfx
HWPC event values of the master rank, sum of threads. count unit in Giga (x 10e9)
-       :      FP_OPS    [GFlops]
section1 :       8.123      17.015
section2 :       4.033      16.919

-------------------------------------------------
Elapsed time variation over MPI ranks
section1
MPI_rank       call       accm[s] accm[%]    waiting[s]  accm/call[s]    flop|msg     speed
#0    :          2  4.773922e-01   66.20  1.392794e-02  2.386961e-01   8.123e+09    17.02 Gflops
#1    :          2  4.913201e-01   68.13  0.000000e+00  2.456601e-01   8.123e+09    16.53 Gflops
section2
MPI_rank       call       accm[s] accm[%]    waiting[s]  accm/call[s]    flop|msg     speed
#0    :          1  2.383769e-01   33.05  0.000000e+00  2.383769e-01   4.033e+09    16.92 Gflops
#1    :          1  2.352839e-01   32.62  3.093004e-03  2.352839e-01   4.033e+09    17.14 Gflops
```

Pmlibを用いる　京実行結果例 (3)

- 環境変数を追加　export HWPC_CHOOSER=FLOPS,VECTOR

PMlib detected the CPU architecture:
The available Hardware Performance Counter (HWPC) events depend on this CPU architecture.
Sun
Fujitsu SPARC64 VIIIfx
HWPC event values of the master rank, sum of threads. count unit in Giga (x 10e9)

- :	FP_OPS	[GFlops]	VEC_INS	FMA_INS
section1 :	8.123	17.010	3.180	0.881
section2 :	4.033	16.758	1.581	0.435

HWPC events legend: count unit in Giga (x 10e9)
FP_OPS: floating point operations
VEC_INS: vector instructions
FMA_INS: Fused Multiply-and-Add instructions
LD_INS: memory load instructions
SR_INS: memory store instructions
L1_TCM: level 1 cache miss
L2_TCM: level 2 cache miss (by demand and by prefetch)
L2_WB_DM: level 2 cache miss by demand with writeback request
L2_WB_PF: level 2 cache miss by prefetch with writeback request
TOT_CYC: total cycles
MEM_SCY: Cycles Stalled Waiting for memory accesses
STL_ICY: Cycles with no instruction issue
TOT_INS: total instructions
FP_INS: floating point instructions
Derived statistics:
[GFlops]: floating point operations per nano seconds (10^-9)
[Mem GB/s]: memory bandwidth in load+store GB/s
[L1$ %]: Level 1 cache hit percentage
[LL$ %]: Last Level cache hit percentage

Pmlibを用いる　京実行結果例 (4)

- 環境変数を変更　export HWPC_CHOOSER=BANDWIDTH

```
Statistics per MPI process [Node Average]
Label    |     call     |            accumulated time                |         flop | messages[Bytes]
         |              |   avr[sec]    avr[%]     sdv[sec]  avr/call[sec] |   avr         sdv         speed
---------+--------------+-------------------------------------------------+-------------------------------------
section1 :            2   4.823370e-01   66.93   3.7025e-03  2.411685e-01    1.007e+10   6.975e+08    19.45 GB/sec
section2 :            1   2.383659e-01   33.07   2.4961e-03  2.383659e-01    5.227e+09   6.785e+08    20.42 GB/sec
---------+--------------+-------------------------------------------------+-------------------------------------
Total    |               7.207029e-01                                 1.530e+10               19.77 GB/sec
Performance|                                                                                    39.54 GB/sec

-----------------------------------------------------
PMlib detected the CPU architecture:
The available Hardware Performance Counter (HWPC) events depend on this CPU architecture.
          Sun
          Fujitsu SPARC64 VIIIfx
HWPC event values of the master rank, sum of threads. count unit in Giga (x 10e9)
-        :      L2_TCM    L2_WB_DM    L2_WB_PF  [Mem GB/s]
section1 :       0.082       0.000       0.000      22.025
section2 :       0.045       0.000       0.000      23.763

          HWPC events legend: count unit in Giga (x 10e9)
                    FP_OPS: floating point operations
                    VEC_INS: vector instructions
                    FMA_INS: Fused Multiply-and-Add instructions
                    LD_INS: memory load instructions
                    SR_INS: memory store instructions
                    L1_TCM: level 1 cache miss
                    L2_TCM: level 2 cache miss (by demand and by prefetch)
                    L2_WB_DM: level 2 cache miss by demand with writeback request
                    L2_WB_PF: level 2 cache miss by prefetch with writeback request
```

参考資料　OpenMPプログラムへの組み込み

```
#include <omp.h>
int main (int argc, char *argv[])
{
        matrix.nsize = nsize;
        set_array();

        int loop=3;
        for (int i=1; i<=loop; i++){
                subkerel();
        }

        return 0;
}

void subkerel()
{
int i, j, k, nsize;
float c1,c2,c3;
nsize = matrix.nsize;
#pragma omp parallel
#pragma omp for
        for (i=0; i<nsize; i++){
        for (j=0; j<nsize; j++){
            …
}
```

```
#include <omp.h>
#include <PerfMonitor.h>
using namespace pm_lib;
PerfMonitor PM;

int main (int argc, char *argv[])
{
int my_id=0, num_threads, npes=1;
char parallel_mode[] = "OpenMP";
double flop_count, dsize;
matrix.nsize = nsize;
dsize = (double)nsize;
num_threads  = omp_get_max_threads();
PM.initialize();
PM.setParallelMode(parallel_mode, num_threads, npes);
PM.setRankInfo(my_id);
PM.setProperties("check_2", PerfMonitor::CALC);

set_array();
flop_count=pow (dsize, 3.0)*4.0;

PM.start("check_2");
int loop=3;
for (int i=1; i<=loop; i++){
       subkerel();
}
PM.stop ("check_2", flop_count, 1);
PM.gather();
PM.print(stdout, "London", "Mr. Bean");
PM.printDetail(stdout);
return 0;
}
```

ソースプログラム全体は example/ ディレクトリにあります

ハンズオン

- ハンズオンプログラムについて
- プログラムの実行
- プログラムへのPMlibのくみこみ
- プログラムのPMlib統計情報の解釈と検討

ハンズオンプログラムについて

- 立方体領域の熱伝導問題
- 主要な計算はラプラス方程式の差分解法
- 解法のオプションとしてJacobi法とSOR法を選択可能
- 1プロセス実行用
- スレッド並列化用のOpenMP指示行含む
- プログラム言語
  - メインプログラム：C++
  - 主要な計算サブルーチン： Fortran

ハンズオンプログラムの構成

```
Main()
{
        bc_();
        src_dirichlet_();
        case JACOBI:
         for (loop=1; loop<=ItrMax; loop++)
         {
              jacobi_();      排他測定区間”Jacobi_kernel”
              bc_();          排他測定区間”BoundaryCondition”
         }
        case SOR:
         for (loop=1; loop<=ItrMax; loop++)
        {
              psor_();        排他測定区間”Sor_kernel”
              bc_();          排他測定区間”BoundaryCondition”
        }
}
```

非排他測定区間
”Jacobi”

非排他測定区間
” PointSOR”

ハンズオンプログラムについて

- ソースプログラム

```
$ ls -go *.cpp *.f90 *.h
-rw-r--r--  1    927 12 26 20:57 FortFunc.h
-rw-r--r--  1   1550 12 26 12:53 kernel_def.h
-rw-r--r--  1   5935 12 26 12:53 linear_solver.f90
-rw-r--r--  1   6344  1 15 22:47 main_PMlib.cpp
-rw-r--r--  1   6674  1 15 23:16 main_base.cpp
-rw-r--r--  1    476 12 26 20:56 realtype.h
```

- Makefile

```
 ls -go Makefile.*
-rw-r--r--  1   1324  1 16 01:02 Makefile.K
-rw-r--r--  1   1215  1 16 01:03 Makefile.intel
-rw-r--r--  1   1326  1 15 23:29 Makefile.macosx
```

プログラムのmakeと実行

- ハンズオンプログラム・ベース版
  - プログラムは実際にはPMlibを呼び出さないが、Makefileはは PMlib使用版と同じ物を用いる
  - インストールしたPMlib用の環境変数が正しく設定されていることを確認後、makeする

```
$ PMLIB_ROOT=${HOME}/pmlib
$ export PMLIB_INCLUDES="-I${PMLIB_ROOT}/include"
$ export PMLIB_LDFLAGS="-L${PMLIB_ROOT}/lib -lPM"

$ PAPI_ROOT=/usr/local/papi/papi-5.3.2/intel
$ export PAPI_INCLUDE="-I${PAPI_ROOT}/include"
$ export PAPI_LDFLAGS="-L${PAPI_ROOT}/lib -lpapi -lpfm"
$ export PMLIB_LDFLAGS="-L${PMLIB_ROOT}/lib -lPM -lpapi_ext"

$ cp main_base.cpp main.cpp
$ make -f Makefile.K
$ time OMP_NUM_THREADS=1 ./kernel.ex 128 jacobi 1000
```

プログラムへのPMlibの組み込み

- ハンズオンプログラム・PMlib版の作成
  - main.cpp のソースプログラムでコメントアウトされている PMlib関数呼び出し箇所を有効化する(//if_use_Pmlibと書かれている22箇所)

```
//if_use_PMlib     PerfMonitor PM;
//if_use_PMlib     PM.initialize( PM_NUM_MAX );
```

```
PerfMonitor PM;
PM.initialize( PM_NUM_MAX );
```

  - 全て有効化するとソースプログラムは main_PMlib.cpp と同一内容となる
  - 実際にソースを編集してみると雰囲気がわかるので、無駄手間に思えても一度やってみることをオススメ

PMlib組み込みプログラムの実行

```
$ cp main_PMlib.cpp main.cpp
$ make -f Makefile.K
$ time OMP_NUM_THREADS=1 ./kernel.ex 128 jacobi 1000
```

参考資料

- プロセッサ固有のハードウエアパフォーマンスカウンタ（HWPC)について
- 京のHWPCとPAPIインタフェイス
- Intel XeonのHWPCとPAPIインタフェイス
- PAPI 高水準インタフェイスと低水準インタフェイス

ハードウエアカウンタについて

- 京・FX10 preset event

Available events and hardware information.

Vendor string and code : Sun (7)
Model string and code : Fujitsu SPARC64 IXfx (141)
CPU Revision : 0.000000
CPU Megahertz : 1650.000000
CPU Clock Megahertz : 1650
CPU's in this Node : 16
Nodes in this System : 1
Total CPU's : 16
Number Hardware Counters : 8
Max Multiplex Counters : 512

Name	Code	Deriv	Description (Note)
PAPI_L1_DCM	0x80000000	No	Level 1 data cache misses
PAPI_L1_ICM	0x80000001	No	Level 1 instruction cache misses
PAPI_L1_TCM	0x80000006	Yes	Level 1 cache misses
PAPI_L2_TCM	0x80000007	Yes	Level 2 cache misses
PAPI_CA_INV	0x8000000c	No	Requests for cache line invalidation
PAPI_CA_ITV	0x8000000d	No	Requests for cache line intervention
PAPI_TLB_DM	0x80000014	No	Data translation lookaside buffer misses
PAPI_TLB_IM	0x80000015	No	Instruction translation lookaside buffer misses
PAPI_TLB_TL	0x80000016	Yes	Total translation lookaside buffer misses
PAPI_MEM_SCY	0x80000022	No	Cycles Stalled Waiting for memory accesses
PAPI_STL_ICY	0x80000025	No	Cycles with no instruction issue
PAPI_FUL_ICY	0x80000026	No	Cycles with maximum instruction issue
PAPI_STL_CCY	0x80000027	Yes	Cycles with no instructions completed
PAPI_FUL_CCY	0x80000028	Yes	Cycles with maximum instructions completed
PAPI_HW_INT	0x80000029	No	Hardware interrupts
PAPI_BR_MSP	0x8000002e	No	Conditional branch instructions mispredicted
PAPI_BR_PRC	0x8000002f	Yes	Conditional branch instructions correctly predicted
PAPI_FMA_INS	0x80000030	Yes	FMA instructions completed
PAPI_TOT_IIS	0x80000031	Yes	Instructions issued
PAPI_TOT_INS	0x80000032	No	Instructions completed
PAPI_FP_INS	0x80000034	Yes	Floating point instructions
PAPI_LD_INS	0x80000035	Yes	Load instructions
PAPI_SR_INS	0x80000036	Yes	Store instructions
PAPI_BR_INS	0x80000037	No	Branch instructions
PAPI_VEC_INS	0x80000038	Yes	Vector/SIMD instructions
PAPI_TOT_CYC	0x8000003b	No	Total cycles
PAPI_LST_INS	0x8000003c	No	Load/store instructions completed
PAPI_L2_TCH	0x80000056	Yes	Level 2 total cache hits
PAPI_L2_TCA	0x80000059	Yes	Level 2 total cache accesses
PAPI_FP_OPS	0x80000066	Yes	Floating point operations

ハードウエアカウンタについて

- Intel Xeon E5 preset event

Hdw Threads per core : 1
Cores per Socket : 8
Sockets : 2
NUMA Nodes : 2
CPUs per Node : 8
Total CPUs : 16
Running in a VM : no
Number Hardware Counters : 11
Max Multiplex Counters : 32

Name Code Deriv Description (Note)
PAPI_L1_DCM 0x80000000 No Level 1 data cache misses
PAPI_L1_ICM 0x80000001 No Level 1 instruction cache misses
PAPI_L2_DCM 0x80000002 Yes Level 2 data cache misses
PAPI_L2_ICM 0x80000003 No Level 2 instruction cache misses
PAPI_L1_TCM 0x80000006 Yes Level 1 cache misses
PAPI_L2_TCM 0x80000007 No Level 2 cache misses
PAPI_L3_TCM 0x80000008 No Level 3 cache misses
PAPI_TLB_DM 0x80000014 Yes Data translation lookaside buffer misses
PAPI_TLB_IM 0x80000015 No Instruction TLBmisses
PAPI_L1_LDM 0x80000017 No Level 1 load misses
PAPI_L1_STM 0x80000018 No Level 1 store misses
PAPI_L2_STM 0x8000001a No Level 2 store misses
PAPI_STL_ICY 0x80000025 No Cycles with no instruction issue
PAPI_BR_UCN 0x8000002a Yes Unconditional branch instructions
PAPI_BR_CN 0x8000002b No Conditional branch instructions
PAPI_BR_TKN 0x8000002c Yes Conditional branch taken
PAPI_BR_NTK 0x8000002d No Conditional branch not taken
PAPI_BR_MSP 0x8000002e No Conditional branch mispredicted
PAPI_BR_PRC 0x8000002f Yes Conditional branch correctly predicted
PAPI_TOT_INS 0x80000032 No Instructions completed
PAPI_FP_INS 0x80000034 Yes Floating point instructions
PAPI_LD_INS 0x80000035 No Load instructions
PAPI_SR_INS 0x80000036 No Store instructions
PAPI_BR_INS 0x80000037 No Branch instructions
PAPI_TOT_CYC 0x8000003b No Total cycles
PAPI_L2_DCH 0x8000003f Yes Level 2 data cache hits
PAPI_L2_DCA 0x80000041 No Level 2 data cache accesses
PAPI_L3_DCA 0x80000042 Yes Level 3 data cache accesses
PAPI_L2_DCR 0x80000044 No Level 2 data cache reads
PAPI_L3_DCR 0x80000045 No Level 3 data cache reads
PAPI_L2_DCW 0x80000047 No Level 2 data cache writes
PAPI_L3_DCW 0x80000048 No Level 3 data cache writes
PAPI_L2_ICH 0x8000004a No Level 2 instruction cache hits
PAPI_L2_ICA 0x8000004d No Level 2 instruction cache accesses
PAPI_L3_ICA 0x8000004e No Level 3 instruction cache accesses
PAPI_L2_ICR 0x80000050 No Level 2 instruction cache reads
PAPI_L3_ICR 0x80000051 No Level 3 instruction cache reads
PAPI_L2_TCA 0x80000059 Yes Level 2 total cache accesses
PAPI_L3_TCA 0x8000005a No Level 3 total cache accesses
PAPI_L2_TCR 0x8000005c Yes Level 2 total cache reads
PAPI_L3_TCR 0x8000005d Yes Level 3 total cache reads
PAPI_L2_TCW 0x8000005f No Level 2 total cache writes
PAPI_L3_TCW 0x80000060 No Level 3 total cache writes
PAPI_FDV_INS 0x80000063 No Floating point divide instructions
PAPI_FP_OPS 0x80000066 Yes Floating point operations
PAPI_SP_OPS 0x80000067 Yes Floating point operations; optimized to count scaled single precision vector operations
PAPI_DP_OPS 0x80000068 Yes Floating point operations; optimized to count scaled double precision vector operations
PAPI_VEC_SP 0x80000069 Yes Single precision vector/SIMD instructions
PAPI_VEC_DP 0x8000006a Yes Double precision vector/SIMD instructions
PAPI_REF_CYC 0x8000006b No Reference clock cycles

ハードウエアカウンタ Xeon E5 preset とnative

Intel Xeon E5ではPAPI_FP_OPSとPAPI_FP_INSは同じ内容を表示

```
Event name:                    PAPI_FP_OPS
Event Code:                    0x80000066
Number of Native Events:       2
Short Description:            |FP instructions|
Long Description:             |Floating point instructions|
Developer's Notes:            ||
Derived Type:                 |DERIVED_ADD|
Postfix Processing String:    ||
 Native Code[0]: 0x4000001c |FP_COMP_OPS_EXE:SSE_SCALAR_DOUBLE|
 Native Event Description: |Counts number of floating point events, masks:Number of SSE double precision FP scalar uops executed|

 Native Code[1]: 0x4000001d |FP_COMP_OPS_EXE:SSE_FP_SCALAR_SINGLE|
 Native Event Description: |Counts number of floating point events, masks:Number of SSE single precision FP scalar uops executed|


$ papi_avail -e  PAPI_DP_OPS
Event name:                    PAPI_DP_OPS
Event Code:                    0x80000068
Number of Native Events:       3
Short Description:            |DP operations|
Long Description:             |Floating point operations; optimized to count scaled double precision vector operations|

 Native Code[0]: 0x4000001c |FP_COMP_OPS_EXE:SSE_SCALAR_DOUBLE|
 Native Event Description: |Counts number of floating point events, masks:Number of SSE double precision FP scalar uops executed|

 Native Code[1]: 0x40000020 |FP_COMP_OPS_EXE:SSE_FP_PACKED_DOUBLE|
 Native Event Description: |Counts number of floating point events, masks:Number of SSE double precision FP packed uops executed|

 Native Code[2]: 0x40000021 |SIMD_FP_256:PACKED_DOUBLE|
 Native Event Description: |Counts 256-bit packed floating point instructions, masks:Counts 256-bit packed double-precision|


$ papi_avail -e  PAPI_VEC_DP
Event name:                    PAPI_VEC_DP
Event Code:                    0x8000006a
Number of Native Events:       2
Short Description:            |DP Vector/SIMD instr|
Long Description:             |Double precision vector/SIMD instructions|

 Native Code[0]: 0x40000020 |FP_COMP_OPS_EXE:SSE_FP_PACKED_DOUBLE|
 Native Code[1]: 0x40000021 |SIMD_FP_256:PACKED_DOUBLE|
```

ハードウエアカウンタ SPARC64 VIIIfx preset とnative

```
$ papi_avail -e PAPI_FP_OPS

Event name:                    PAPI_FP_OPS
Number of Native Events:       4
Short Description:            |FP operations|
Long Description:             |Floating point operations|
Derived Type:                 |DERIVED_POSTFIX|

 Native Code[0]: 0x40000010  |FLOATING_INSTRUCTIONS|
 Native Event Description:   |Counts the number of committed floating-point operation instructions.|

 Native Code[1]: 0x40000011  |FMA_INSTRUCTIONS|
 Native Event Description:   |Counts the number of committed floating-point Multiply-and-Add operation instructions.|

 Native Code[2]: 0x40000008  |SIMD_FLOATING_INSTRUCTIONS|
 Native Event Description:   |Counts the number of committed floating-point SIMD instructions of one operation in SIMD.|

 Native Code[3]: 0x40000009  |SIMD_FMA_INSTRUCTIONS|
 Native Event Description:   |Counts the number of committed floating-point SIMD instructions of two operation in SIMD.|
```